



Manual Técnico de Infraestructura en la Nube

Proyecto Atena — NeuroK AR (Fundación Universitaria Konrad Lorenz)

Documento preparado para entrega institucional al Laboratorio de Neurociencias Aplicadas – NeuroK

Fecha: Septiembre 2026 (Versión 3.0 — Consolidación Cloud Native Groq LPU + ONNX Runtime)

Autores: Viviana Marcela García Valderrama — Braian Felipe Ramirez Ortiz




Tabla de Contenidos

1. [Resumen del Ecosistema](#)
 2. [Evolución Arquitectónica: De Docker Local \(Ollama\) a Cloud Gemini y la Arquitectura Definitiva \(Groq LPU + ONNX\)](#)
 3. [Cuenta Institucional del Proyecto](#)
 4. [Repositorio de Código — GitHub](#)
 5. [Backend en la Nube — Render.com](#)
 6. [Base de Datos NoSQL — Firebase Firestore \(Conexión y Flujo de Datos\)](#)
 7. [Modelos de IA — Inferencia Groq LPU y Embeddings ONNX Runtime](#)
 8. [API REST — Endpoints y Funcionamiento](#)
 9. [Script para Unity — AtenaClient.cs](#)
 10. [Cómo Agregar y Vectorizar Nueva Literatura Científica](#)
 11. [Cómo Administrar el Sistema](#)
 12. [Monitoreo, Tiempos de Respuesta y Manejo del Cold Start](#)
 13. [Ficha Técnica Final de Entrega](#)
-

1. Resumen del Ecosistema

El proyecto está compuesto por **cuatro capas desacopladas** que trabajan juntas de forma integrada y en tiempo real:



2. Evolución Arquitectónica: De Docker Local (Ollama) a Cloud Gemini y la Arquitectura Definitiva (Groq LPU + ONNX)

El sistema atravesó un riguroso proceso de maduración de ingeniería en tres etapas sucesivas:

1. Fase 1 (Prototipo Local con Ollama y Docker):

Ejecutaba modelos locales (Llama 3.2 3B/8B) en una laptop de desarrollo. Presentó cuellos de botella severos: latencias de 25 a 55 segundos, sobrecarga térmica de CPU (88-95% sostenido a 92°C), saturación de memoria RAM (14.8 GB sobre 16 GB) y caídas de cuadros en Unity 3D a menos de 12 FPS.

2. Fase 2 (Prueba Piloto Cloud con Google Gemini API):

Descargó el procesamiento local hacia la nube de Google AI Studio, reduciendo el tiempo de

respuesta a 1.8 segundos. No obstante, al someter el sistema a pruebas de concurrencia e integración con Unity, surgieron bloqueos por límites de cuota gratuita (**HTTP 429 Too Many Requests / ResourceExhausted** limitado a 15 peticiones por minuto) y fluctuaciones de latencia en horas pico.

- 3. **Fase 3 (Arquitectura Definitiva: Groq LPU + ChromaDB ONNX Runtime en Render):**
- 4. **Inferencia LLM:** Migración a Groq Cloud con tecnología LPU (*Language Processing Unit*). Generación ultra-veloz (>350 tokens/segundo) y latencia sub-segundo (< 0.9s).
- 5. **Embeddings y Memoria del Servidor:** Reemplazo de PyTorch por ONNX Runtime (ONNXMiniLM_L6_V2). El consumo de RAM en reposo del servidor cayó de 520 MB a menos de 140 MB (-73%), resolviendo de manera definitiva las caídas por falta de memoria (**Out Of Memory - 512Mi limit**) en el plan gratuito de Render.
- 6. **Robustez RAG:** Búsqueda híbrida y *Fuzzy Matching* que corrige automáticamente errores ortográficos comunes en neuroanatomía (hipicampo $\rightarrow$ hipocampo) y genera citas bibliográficas exactas ([Fuente X, pág. Y]).

Comparativa Técnica Integral de las Tres Fases

Criterio	Fase 1: Ollama (Local)	Fase 2: Gemini API (Cloud Piloto)	Fase 3: Groq LPU + ONNX (Actual / Definitiva)
¿Dónde corre?	En la laptop local (Docker)	Nube Google AI Studio + Render	Nube Groq Cloud (LPU) + Render
Tiempo de Respuesta	25 a 55 segundos (Hiper lento)	1.5 a 3.5 segundos (Inestable en horas pico)	0.6 a 0.9 segundos (Casi instantáneo)
Velocidad (Tokens/s)	4 - 6 tokens/segundo	60 - 95 tokens/segundo	> 380 tokens/segundo
Memoria RAM Servidor	Satura la laptop (14.8 GB)	520 MB (Tumbaba el servidor de Render)	< 140 MB (Súper liviano y estable)
Límite de Peticiones	Ilimitado pero congelaba la PC	Máximo 15 preguntas/minuto (Error 429)	Sin bloqueos ni caídas de cuota
Integración con Unity	Congelaba la escena (< 12 FPS)	Fluido, pero a veces fallaba el JSON	60 FPS estables y JSON perfecto
Citas y Fuentes	Genéricas / Sin página	Mencionaba el libro sin página exacta	Exactas: [Fuente X, pág. Y]

Criterio	Fase 1: Ollama (Local)	Fase 2: Gemini API (Cloud Piloto)	Fase 3: Groq LPU + ONNX (Actual / Definitiva)
Tolerancia Tipográfica	Nula (falla si hay errores tipográficos)	Baja (dependencia exclusiva de similitud vectorial)	Alta (Fuzzy Matching automático con difflib)
Costo Mensual	\$0 (pero exigía PC de \$2,500 USD)	\$0 (con cuota muy restringida)	\$0 USD permanente

3. Cuenta Institucional del Proyecto

Para asegurar la **soberanía tecnológica** y la transferencia ordenada al Laboratorio NeuroK, todos los servicios están centralizados bajo la cuenta oficial:

Campo	Valor
Correo Institucional	atena.unikonrad@gmail.com
Contraseña	Se entrega en el acta privada de recepción técnica
Plataformas Vinculadas	Render.com (Servidor API), Groq Cloud Console (Motor LLM), Firebase Console (Firestore NoSQL), GitHub (Código Fuente)

4. Repositorio de Código — GitHub

Campo	Valor
URL del Repositorio	https://github.com/Vivi271/Atena
Tipo de Repositorio	Público (Acceso abierto para auditoría y compilación)
Rama principal	main
Despliegue Continuo (CI/CD)	Vinculado automáticamente con Render via GitHub Webhook

5. Backend en la Nube — Render.com

Configuración del Servicio en Producción

El servicio web está configurado como contenedor Docker en Render:

Parámetro	Valor Configurado
Service Name	Atena
Region	Oregon (US West)
Runtime	Docker
Instance Type	Free (512 MiB RAM / 0.1 CPU compartida — \$0 USD/mes)
Health Check Path	/salud
URL Oficial de Producción	https://atena-vugz.onrender.com

Variables de Entorno en Render

Configuradas de forma segura en el panel de Render (*Environment Variables*):

- GROQ_API_KEY: Clave secreta para la inferencia de lenguaje en Groq Cloud.
- CHROMA_DB_DIR: Ruta relativa al almacén vectorial (chroma_neuro_db).
- SECRET_PIN: Clave de seguridad (1234) para acceder al panel de administración.
- PORT: 8000 (puerto estándar expuesto por el contenedor Docker).

6. Base de Datos NoSQL — Firebase Firestore (Conexión y Flujo de Datos)

¿Qué almacena Firestore en el Proyecto?

Cloud Firestore almacena de forma independiente los datos transaccionales de los estudiantes: - **Colección evaluaciones:** Puntajes de quizzes y progreso pedagógico en AR. - **Colección sesiones_chat:** Historial de interacción para analítica académica del laboratorio. - **Colección metricas_sistema:** Tiempos de respuesta y estructuras cerebrales más consultadas.

Flujo de Comunicación

Unity (NeuroK AR Móvil)

↳

Firestore (gRPC seguro / TLS 1.3) → Guarda métricas y quizzes

↳

Render.com (HTTPS REST /consultar) → Inferencia y consulta RAG

7. Modelos de IA — Inferencia Groq LPU y Embeddings ONNX Runtime

Componentes de Inteligencia Artificial

Función	Tecnología / Modelo	Justificación Técnica
Generación de Respuestas RAG	Groq Cloud LPU — openai/gpt-oss-120b	Inferencia ultra-rápida (>350 tok/s), seguimiento riguroso de contexto científico, cero alucinaciones y adaptación a niveles básico/avanzado.
Vectorización Semántica	ChromaDB Nativo — all-MiniLM-L6-v2 (ONNX)	Generación de embeddings de 384 dimensiones sin requerir PyTorch ni CUDA. Reduce el consumo de RAM a <140 MB, garantizando estabilidad en contenedores de 512 MiB.
Corrección Fonética / Léxica	Fuzzy Matching (difflib)	Intercepta términos anatómicos mal digitados en la pantalla táctil móvil antes de consultar la base de datos.
Estrategia de Cita	Citas Documentales Forzadas	Inyecta metadatos obligatorios en el prompt del sistema: [Fuente X, pág. Y].

8. API REST — Endpoints y Funcionamiento

URL Base de Producción

https://atena-vugz.onrender.com

Endpoints Disponibles

1. POST /consultar (Principal para Unity 3D)

Recibe la consulta del estudiante y devuelve la síntesis RAG con fuentes y páginas verificadas.

- **Request Payload:**

```
{
  "pregunta": "¿Qué función cumple el hipocampo?",
  "nivel": "avanzado",
  "k": 5
}
```

- **Response Payload:**

```
{
  "respuesta": "El hipocampo es una estructura crítica del sistema límbico vinculada a la consoli",
  "fuentes": [
    {
      "fuente": "Neuroanatomia clinica 26va Edición – Lange.pdf",
      "pagina": 214,
      "fragmento": "El hipocampo forma parte del arquicórtex y desempeña un papel central en la c",
    }
  ],
  "nivel": "avanzado"
}
```

2. GET /salud

Endpoint de comprobación de salud (*health-check*). Devuelve el estado del servidor, conectividad de ChromaDB y hora del sistema:

```
{
  "estado": "activo",
  "servicio": "Atena API REST",
  "version": "3.0.0",
  "documentos_indexados": 352
}
```

3. GET /info

Retorna metadatos técnicos, modelos activos y estado de configuración.

4. GET /docs

Interfaz Swagger UI interactiva para pruebas en navegador: <https://atena-vugz.onrender.com/docs>.

9. Script para Unity — AtenaClient.cs


El script oficial en C# gestiona las peticiones asíncronas desde la aplicación móvil: - **Ubicación en el repositorio:** [AtenaClient.cs](#) - **URL Base:** <https://atena-vugz.onrender.com> - **Manejo de Red:** Utiliza `UnityWebRequest` con serialización JSON nativa (`JsonUtility`). - **Callback Desacoplado:** Envía la respuesta formateada a la UI del Canvas sin bloquear el hilo principal de renderizado de Unity (60 FPS sostenidos).

10. Cómo Agregar y Vectorizar Nueva Literatura Científica

Flujo de Persistencia Eficiente (Inmutabilidad en Servidor Gratuito)

Los contenedores gratuitos de Render tienen un sistema de archivos efímero: no deben realizar tareas pesadas de vectorización en caliente para evitar caídas por límite de RAM (512 MiB).

Por tal motivo, la base vectorial `chroma_neuro_db` (~32 MB) está pre-indexada y empaquetada dentro del repositorio.



¿Por qué se actualiza en ambos (GitHub y Render)?

1. **Persistencia y Respaldo Permanente (GitHub):** Los contenedores gratuitos de Render tienen un sistema de archivos efímero (cualquier cambio local se descarta cuando el servidor entra en reposo o se reinicia tras 15 minutos de inactividad). Al almacenarse en

GitHub, el repositorio actúa como la bóveda de respaldo definitiva bajo la cuenta institucional de la Konrad Lorenz.

2. **Despliegue Continuo Automático (Render):** Render está enlazado a GitHub mediante *Webhooks*. En cuanto GitHub recibe la actualización, notifica a Render para reconstruir el contenedor Docker en ~2 minutos, garantizando que la app móvil de Unity siempre consuma la versión más reciente sin intervención manual.

Flujo de Subida para el Personal de Laboratorio (100% Visual — Cero Código)

Para garantizar que los docentes e investigadores de NeuroK no requieran conocimientos de programación ni uso de terminales de comandos, el sistema incluye un **asistente de sincronización en 1 solo clic** desde el panel web de Atena:

Método 1: Panel Web Administrativo (Recomendado para Laboratorio)

1. **Acceder como Administrador:** En la barra lateral de Atena, desplegar el panel de acceso e ingresar el PIN institucional: 1234.
 2. **Arrastrar el Documento:** En la sección « **Base de Conocimientos**», arrastrar los nuevos archivos PDF o DOCX en el recuadro de carga. El motor los procesa, fragmenta y vectoriza inmediatamente en segundo plano.
 3. **Publicar a Unity en 1 Clic:** Debajo de la lista de documentos, presionar el botón:
  **Publicar Cambios a la Nube**
 El sistema empaqueta automáticamente los vectores y los envía a la nube de Render sin que el docente deba abrir una consola ni escribir instrucciones de Git.
 4. **Despliegue Automático:** En 2 minutos, la app móvil de Unity de todos los estudiantes queda sincronizada con la nueva literatura científica.
-

Método 2: Por Consola / Terminal (Para Desarrolladores)

Si un ingeniero de sistemas desea realizar la indexación de forma manual: 1. Copiar el archivo PDF/DOCX en la carpeta Docs/. 2. Ejecutar: `bash python indexar_documentos.py git add Docs/chroma_neuro_db/ git commit -m "docs: indexar nuevo texto de neuroanatomía" git push origin main` 3. Render compilará el contenedor automáticamente.

11. Cómo Administrar el Sistema

Plataforma	Propósito	URL de Acceso	Credenciales
Render.com	Servidor Backend Docker	dashboard.render.com	atena.unikonrad@gmail.com
Groq Console	Monitoreo y API Keys LLM	console.groq.com	atena.unikonrad@gmail.com
Firebase Console	Base de Datos NoSQL Firestore	console.firebase.google.com	atena.unikonrad@gmail.com
GitHub	Código Fuente y Control de Versiones	github.com/Vivi271/Atena	Repositorio Oficial

12. Monitoreo, Tiempos de Respuesta y Manejo del Cold Start

Comportamiento del Servidor Gratuito (Cold Start)

En la capa gratuita de Render, la instancia entra en estado de suspensión (*sleep*) tras **15 minutos sin tráfico entrante**. - **Impacto:** La primera consulta recibida después de un periodo de inactividad puede tardar **entre 30 y 45 segundos** mientras Render despierta el contenedor Docker. - **A partir de la segunda consulta:** El servidor responde a velocidad plena en **0.6 a 0.9 segundos**.

Estrategia de Mitigación para Prácticas y Sustentaciones

- Despertar Previo:** Abrir la URL <https://atena-vugz.onrender.com/salud> en cualquier navegador 1 minuto antes de iniciar una clase, práctica de laboratorio o sustentación de tesis.
- Monitoreo Automático Gratuito (Opcional):** Configurar un servicio gratuito de monitoreo tipo *UptimeRobot* (<https://uptimerobot.com>) que envíe una petición GET `/salud` cada 14 minutos, impidiendo que el servidor entre en reposo durante las jornadas académicas.

13. Ficha Técnica Final de Entrega

Parámetro	Detalle Institucional
Nombre del Proyecto	Atena — Consultor RAG en Neuroanatomía 3D
Aplicación Móvil Cliente	NeuroK AR (Unity 3D / C# / Android)

Parámetro	Detalle Institucional
Institución Académica	Fundación Universitaria Konrad Lorenz
Laboratorio Destino	Laboratorio de Neurociencias Aplicadas – NeuroK
Autores	Viviana Marcela García Valderrama — Braian Felipe Ramirez Ortiz
Año y Versión	2026 — Versión 3.0 (Cloud Native Consolidada)
URL Base de Producción	https://atena-vugz.onrender.com
Health Check	https://atena-vugz.onrender.com/salud
Documentación Swagger	https://atena-vugz.onrender.com/docs
Repositorio GitHub	https://github.com/Vivi271/Atena
Motor de Inferencia LLM	Groq Cloud LPU — openai/gpt-oss-120b
Velocidad de Inferencia	>350 tokens/segundo (Latencia promedio: 0.8s)
Modelo de Embeddings	ChromaDB Nativo — all-MiniLM-L6-v2 (ONNX Runtime, 384 dim)
Almacenamiento Vectorial	ChromaDB Persistent Store (chroma_neuro_db, ~32 MB)
Consumo de RAM en Servidor	< 140 MB (Operación holgada dentro de los 512 MiB de Render)
Tolerancia a Fallos de Usuario	Fuzzy Matching léxico y Búsqueda Híbrida
Citas Documentales	Trazabilidad exacta por texto y página: [Fuente X, pág. Y]
Costo Operativo Mensual	\$0 USD (100% Permanente)

Manual Técnico de Infraestructura — Documento Oficial de Entrega — Facultad de Psicología / Ingeniería de Sistemas — Fundación Universitaria Konrad Lorenz.